Análisis predictivo de riesgo de corrupción en contratación pública mediante aprendizaje automático

Aragón Jhojan, Juan Amaya, Santiago Buitrago

Resumen

Este proyecto propone la aplicación de técnicas de aprendizaje automático para el análisis predictivo del riesgo de corrupción en la contratación pública en Colombia. A partir de datos de SECOP II, se seleccionarán variables relevantes para entrenar modelos de clasificación que permitan identificar contratos con alta probabilidad de presentar irregularidades. La metodología incluye validación cruzada y evaluación mediante métricas como AUC-ROC y F1-score. El propósito es desarrollar un sistema de alertas tempranas que fortalezca la vigilancia preventiva y contribuya a una gestión más transparente y eficiente de los recursos públicos.

Index Terms

Elefantes Blancos, Sistema General de Regalías, Contratación pública, SECOP II, Aprendizaje automático, XGBoost, Random Forest, Alertas tempranas, Detección de anomalías, Auditoría preventiva

ÍNDICE

I. Descripción del Documento 2

II. Identifiación del Problema 2

III. Justificación 2

IV. Estado del arte 3
- IV-A. Métodos técnicos basados en Inteligencia Artificial y *Machine Learning* . . . 3
- IV-B. Aplicaciones directas en SECOP y contratación pública . . . 3
- IV-C. Contexto colombiano: corrupción, control institucional y gobierno abierto . . . 4
- IV-D. Marco normativo y jurídico de la contratación pública . . . 4
- IV-E. Transparencia y gobernanza de datos abiertos . . . 4

V. Marco Teórico 5
- V-A. Contratación pública, corrupción y riesgo . . . 5
- V-B. Detección de corrupción y colusión basada en datos . . . 5
- V-C. Aprendizaje automático para la predicción de riesgos . . . 5
- V-D. Evaluación de modelos y construcción de la variable objetivo . . . 6

VI. Objetivos 7
- VI-A. Objetivo General . . . 7
- VI-B. Objetivos Específicos . . . 7

VII. Alcance del Proyecto 7
- VII-A. Entregables Funcionales . . . 8
- VII-B. Área de Estudio . . . 8
- VII-C. Frontera del Proyecto . . . 8

VIII. Limitaciones del Proyecto 8
- VIII-A. Limitaciones Técnicas . . . 8
- VIII-B. Limitaciones de los Datos . . . 8
  - VIII-B1. No existe una etiqueta oficial de incumplimiento . . . 9
  - VIII-B2. Calidad irregular de los registros . . . 9
  - VIII-B3. El modelo no ve lo que no está publicado . . . 9

Universidad Distrital Francisco Jose De Caldas, Colombia
jhsaragonr@udistrital.edu.co
Documento Marzo 2026

IX. Plan de Trabajo 9

X. Cronograma 10
X-A. Diagrama de Gantt . . . 10
X-B. Tabla de Hitos . . . 10

Referencias 10

ÍNDICE DE FIGURAS

1. Esquema conceptual del enfoque de detección de riesgo en contratación pública. . . . 5
2. Matriz de confusión para clasificación binaria de riesgo contractual. . . . 6
3. Diagrama de Gantt – Cronograma del proyecto (16 semanas). . . . 10

ÍNDICE DE TABLAS

I. Plan de trabajo por fases y actividades . . . 9
II. Hitos del proyecto . . . 10

I. DESCRIPCIÓN DEL DOCUMENTO

Introduccion

II. IDENTIFIACIÓN DEL PROBLEMA

Colombia históricamente ha tenido problemas con la ejecución de proyectos de infraestructura que están financiados por el Sistema General de Regalías (SGR) algunos de los problemas en los que se ha visto afectada han sido asociados con retrasos, sobrecostos, incumplimientos contractuales e incluso el abandono de obras, muchos de estos estan relacionados con la corrupción en la que está sumergido este pais, lo que ha generado los denominados “Elefantes Blancos” que son todos aquellos proyectos o infraestructura costosa de mantener que genera más gastos que beneficios, resultando que esta sea inútil y difícil de deshacerse de ella. Esta problemática no solo es generada por la ineficiencia en la gestión de los recursos. Sino que también genera impedimentos en el desarrollo social y económicos de las regiones beneficiaras.

Pese a los esfuerzos institucionales para mejorar los mecanismos de control y vigilancia, La gran mayoría de las acciones de auditoria continúan siendo de carácter reactivo, es decir, toman acción una vez el daño se ha materializado o cuando se ve un contratiempo visible en la ejecución del proyecto. Lo anterior reduce la capacidad de las entidades de control para la prevención de irregularidades que puede haber en un proyecto público.

En este entorno, la accesibilidad de grandes volúmenes de datos que provienen de plataformas como SECOP II, que es una plataforma transaccional en la cual las entidades estatales y los proveedores hacen toda la gestión en línea y en tiempo real de todas las etapas de los procesos de contratación, en ellos encontramos procesos como: planeación, selección, ejecución y liquidación, Gracias a estas plataformas se abren nuevos caminos para el análisis predictivo a través de técnicas de Machine Learning. Pese a lo anterior en la actualidad no se cuenta con alguna herramienta sistemática que disponga de variables contractuales y financieras para hacer un predicción o anticipación desde la etapa de selección, por lo tanto, hay una alta probabilidad que los proyectos presenten contratiempos en su ejecución.

Debido a esto, surge la necesidad de desarrollar una herramienta que implemente modelos predictivos que permita identificar de manera temprana contratos con alto riesgo de convertirse en “Elefantes Blancos” y proyectos que puedan estar bajo procesos irregulares, contribuyendo a que los entes de control cambien de un enfoque reactivo a uno preventivo. Este planteamiento no solo fortalecería la toma de decisiones de las entidades de control, sino que también promovería una gestión más eficiente, transparente y responsable en el manejo de los recursos públicos en proyectos estatales.

III. JUSTIFICACIÓN

La contratación pública en Colombia constituye un mecanismo fundamental para la ejecución de proyectos de infraestructura y desarrollo social. Sin embargo, la persistencia de ineficiencias y riesgos en su gestión ha generado impactos negativos tanto en el uso de los recursos públicos como en el bienestar de las comunidades.

Por lo general, los mecanismos de control y vigilancia en la contratación estatal han actuado bajo un enfoque reactivo, actuando una vez el daño patrimonial se ha realizado. Este enfoque limita la capacidad de las entidades de control para prevenir riesgos y optimizar la asignación de recursos en los procesos de auditoría. A raíz de esto, diferentes estudios han planteado la necesidad de cambiar a un esquema de control preventivo que se apoye en el análisis de datos y el uso de tecnologías emergentes, como el machine learning.

En los últimos años, el crecimiento de plataformas de datos abiertos como SECOP II ha permitido el acceso a grandes volúmenes de datos estructurados sobre procesos en la contratación pública. Estos datos incluyen información de todas las etapas en este proceso. La accesibilidad a estos datos ha impulsado el desarrollo de enfoques basados en machine learning para

la detección de irregularidades, anomalías relacionadas con corrupción y problemas contractuales. Investigaciones previas han demostrado que variables como el tipo de contratación, el número de oferentes y el valor del contrato contienen información que puede ser usado para anticipar comportamientos irregulares desde las primeras etapas del proceso de contratación [1] [2].

Asimismo, Varios trabajos han evidenciado la efectividad de modelos de aprendizaje supervisado como Random Forest, regresión logística y XGBoost han facilitado la predicción de riesgos asociados a proyectos de infraestructura, abarcando retrasos y sobrecostos [3],[4],[5]. En el entorno colombiano, estudios que incluyen datos de plataformas públicas han identificado factores clave que se relacionan con desviaciones de tiempo y costo, lo que resalta la viabilidad de utilizar datos abiertos para este tipo de analisis [6],[7].

Además, desde una perspectiva institucional, el uso de la inteligencia artificial en la contratación pública ha sido reconocido como una herramienta con gran capacidad para mejorar la transparencia y trazabilidad en las decisiones administrativas de igual forma reduce la irregularidades en la información que favorecen la corrupción [8],[9]. De este modo, los sistemas de alertas tempranas se plantean como una alternativa que puede complementar a los mecanismos de control actuales, permitiendo centrar los esfuerzos de supervisión en contratos con mayor probabilidad de riesgo, especialmente en aquellos donde los recursos son limitados. [1],[10].

El presente proyecto se justifica en la necesidad de integrar estos avances teóricos y tecnológicos en una propuesta aplicada al entorno del Sistema General de Regalías (SGR), el cual, concentra una proporción significativa de la inversión pública en infraestructura y ha estado históricamente asociado a problemáticas de ejecución. Pese a la disponibilidad de datos y de los avances en analitica, aun existe una brecha en el desarrollo de herramientas que permitan identificar de manera sistemática, desde la etapa de adjudicación, contratos con alto riesgo de convertirse en proyectos fallidos .

Con esto, el desarrollo de un modelo predictivo que use técnicas de Machine Learning que sea orientado como un sistema que pueda realizar alertas tempranas, no solo representa un gran avance académico en el area de la analitica de datos aplicados a procesos estatales, sino que también una contribución práctica para fortalecer los mecanismos de control. Este tipo de herramienta puede ayudar a entidades de control y veedurías ciudadanas en la toma de decisiones, impulsando una gestión más eficiente, transparente y responsable de los recursos públicos,en concordancia con los principios establecidos en el marco normativo de la contratación estatal [10].

Por último, este trabajo se alinea con las tendencias actuales en un gobierno abierto y el uso de datos públicos, donde la analítica avanzada se posiciona como un elemento clave para mejorar la gobernanza y la transparencia en los procesos. Como señalan varios estudios recientes, cruzar datos abiertos con Machine Learning es un avance para el sector público. Nos permite dejar de ser reactivos y empezar a anticiparnos a los problemas antes de que ocurran [11].

IV. Estado del arte

IV-A. Métodos técnicos basados en Inteligencia Artificial y Machine Learning

Varios investigadores han trabajado en el uso de modelos de aprendizaje automático para detectar problemas en la contratación pública, y sus resultados son bastante relevantes para este trabajo. Por ejemplo, en [1] crearon un sistema de alertas tempranas usando datos del SECOP que buscaba predecir irregularidades contractuales antes de que ocurrieran, aplicando regresión logística y árboles de decisión. Luego, en [2] fueron un paso más allá con el sistema VigIA, implementado en la Alcaldía de Bogotá, que usa *Random Forest* e índices de riesgo para detectar contratos con alta probabilidad de presentar demoras o irregularidades financieras. Los dos estudios coinciden en algo importante: las características del contrato que se conocen desde el momento de la adjudicación, como la modalidad, el valor y el número de oferentes, ya permiten anticipar si un contrato va a tener problemas.

También hay trabajos orientados a detectar colusión entre oferentes. En [12] propusieron un algoritmo basado en mínimos cuadrados regularizados por *kernel* (KRLS) que logra identificar colusión en subastas usando solo datos básicos como el precio adjudicado y el número de participantes, sin necesitar información detallada de los pliegos. Por su parte, en [3] analizaron indicadores de corrupción en licitaciones de obra vial en Italia, comparando LASSO, Ridge y *Random Forest*, y concluyeron que este último modelo tiene mejor desempeño predictivo, especialmente cuando se incluyen variables que no se reportan de forma estándar.

En cuanto a la predicción de sobrecostos y retrasos en proyectos de infraestructura, también existe bastante literatura. En [6] y [7] se enfocaron en Colombia en donde aplicaron enfoques basados en datos de plataformas abiertas del Estado para modelar desviaciones de tiempo y costo en proyectos viales y educativos, encontrando que el tipo de proceso de selección, las adiciones contractuales y el origen de los recursos son variables clave. A nivel internacional, podemos ver que en [4] mostraron que *XGBoost* supera a la regresión lineal en la predicción de costos de construcción, gracias a su capacidad para capturar relaciones no lineales. Más recientemente, en [5] usaron redes neuronales artificiales para predecir retrasos y sobrecostos, logrando un MAPE de 10.93 % para la predicción de retrasos, y destacaron que combinar indicadores cuantitativos y cualitativos mejora notablemente los resultados.

IV-B. Aplicaciones directas en SECOP y contratación pública

SECOP registra prácticamente todo el ciclo de vida de un contrato público: modalidad, número de oferentes, valor adjudicado, modificaciones y estado de ejecución. Esa amplitud lo convierte en la fuente más completa disponible para estudiar contratación

en Colombia, y varios grupos de investigación ya la han aprovechado. Por ejemplo en [8], [9] se agurmeta que trabajar sistemáticamente con esos datos abre la puerta a pasar del control reactivo (que actúa cuando el daño ya ocurrió) a uno preventivo basado en análisis predictivo.

El antecedente más directo de este trabajo es el sistema VigIA [2], desarrollado para la Alcaldía de Bogotá. Usando registros de SECOP II y modelos de *Random Forest*, construyeron índices de riesgo que le permiten a la entidad priorizar qué contratos vigilar. El resultado más útil de ese trabajo no es el modelo en sí, sino lo que demuestra: la información disponible desde la adjudicación ya contiene señales suficientes para separar contratos problemáticos de los que no lo son, antes de que empiece la ejecución.

En una línea similar, en [6] analizan proyectos viales en Colombia y encontraron que tres variables (el tipo de proceso de selección, las adiciones contractuales y la estructura financiera) explican buena parte de las desviaciones en tiempo y costo. En [7] llegan a conclusiones parecidas revisando infraestructura educativa. Ambos trabajos usan plataformas públicas del Estado como fuente de datos, lo que confirma que ese camino es viable metodológicamente.

Este proyecto sigue esa misma lógica, pero desplaza el foco hacia contratos del Sistema General de Regalías (SGR), un universo que concentra montos significativos y una historia documentada de obras inconclusas o “elefantes blancos”.

IV-C. Contexto colombiano: corrupción, control institucional y gobierno abierto

La inteligencia artificial también se ha analizado desde una perspectiva más institucional, pensando en cómo puede apoyar los sistemas de control y transparencia en Colombia. En [8] se argumenta que los sistemas predictivos pueden fortalecer el control fiscal preventivo al detectar patrones anómalos en contratos antes de que se conviertan en problemas. Según los autores, esto también mejora la trazabilidad de las decisiones administrativas y reduce las asimetrías de información que favorecen la corrupción.

En esa misma línea, en [1] se propone que los modelos de alerta temprana son una alternativa complementaria a los enfoques tradicionales de sanción, que actúan después de que el daño ya está hecho. Esto es especialmente relevante en contextos donde los organismos de control no tienen recursos suficientes para auditar todos los contratos.

La apertura de la información contractual genera condiciones que permiten a ciudadanos e investigadores monitorear el comportamiento de los actores involucrados en la contratación pública [9] .

En cuanto a la aceptación institucional, se ha analizado la percepción de funcionarios colombianos frente al uso de IA para combatir la corrupción, encontrando una valoración positiva de su potencial; sin embargo, persisten preocupaciones relacionadas con la transparencia algorítmica y la interpretabilidad de los modelos [10] . Este aspecto resulta clave al diseñar sistemas de este tipo.

IV-D. Marco normativo y jurídico de la contratación pública

La contratación estatal en Colombia opera bajo un conjunto de principios transparencia, economía, responsabilidad y selección objetiva orientados a que el gasto público sea eficiente y verificable [13]. Ese marco no ha permanecido estático: con el tiempo se fue complementando con plataformas digitales y políticas de datos abiertos que buscan hacer más trazable cada peso contratado [9], [14].

Varios autores coinciden en que la transparencia no es solo un valor declarativo sino una condición operativa para reducir la corrupción y sostener la confianza ciudadana en las instituciones [8], [10].Pero en [15] se va un paso más allá y plantea que el verdadero reto de la gobernanza contractual hoy no es aprobar más normas, sino consolidar sistemas de información abiertos que puedan soportar mecanismos de control más sofisticados.

Desde esa perspectiva, construir un modelo predictivo sobre datos de SECOP II no es solo un ejercicio técnico: es coherente con la dirección que el propio marco normativo señala. La vigilancia preventiva que propone este proyecto es, en cierto modo, la traducción práctica de los principios que ya están escritos en la ley.

IV-E. Transparencia y gobernanza de datos abiertos

Un aspecto que no se puede ignorar al desarrollar sistemas analíticos basados en IA es la calidad y disponibilidad de los datos. En [14] se propone el indicador *OpenGovB Transparency Indicator*, que sirve para medir qué tan abiertos son los datos gubernamentales de un país, considerando aspectos como accesibilidad, interoperabilidad y reutilización. Este tipo de marcos ayuda a entender qué tan preparada está una institución para aprovechar sus propios datos en iniciativas analíticas.

Además, algunos investigadores han explorado enfoques basados en redes para analizar las relaciones entre actores dentro de los sistemas de contratación. En [16] se propone modelar a las empresas participantes como nodos y sus interacciones como aristas en un grafo, lo que permite identificar patrones de comportamiento coordinado que podrían indicar colusión o acuerdos anticompetitivos.

V. Marco Teórico

V-A. Contratación pública, corrupción y riesgo

La contratación pública es el mecanismo mediante el cual el Estado transforma recursos fiscales en bienes, servicios y obras para la ciudadanía. En Colombia, su marco normativo (Ley 80 de 1993 y Ley 1150 de 2007) enfatiza transparencia, selección objetiva y eficiencia, pero la literatura evidencia que, aun con reglas formales, persisten vulnerabilidades institucionales y operativas [13], [9].

En ese contexto, el riesgo en contratación no debe entenderse únicamente como "acto corrupto probado", sino como la probabilidad de desviaciones relevantes en costo, plazo o calidad asociadas a patrones de comportamiento observables en los datos contractuales [2], [8]. Esta perspectiva es consistente con enfoques de supervisión preventiva: en lugar de esperar sanciones ex post, se prioriza la detección temprana de contratos con mayor probabilidad de incumplimiento o irregularidad.

La evidencia internacional y regional describe mecanismos recurrentes de afectación del proceso competitivo: colusión entre oferentes, coordinación de precios, rotación de ganadores, direccionamiento de requisitos y fragmentación estratégica de procesos [3], [17], [18]. Todos estos fenómenos reducen la presión competitiva y generan sobrecostos, por lo que son conceptualmente relevantes para este anteproyecto, cuyo problema central es identificar de forma anticipada contratos con señales de alerta en bases como SECOP.

Un aporte clave de la literatura aplicada al sector público es diferenciar *desperdicio activo* (conductas deliberadas para capturar rentas) y *desperdicio pasivo* (ineficiencias por limitaciones técnicas, organizacionales o de diseño institucional) [2]. Esta distinción justifica el enfoque del estudio: el modelo no pretende "probar delito", sino clasificar riesgo operativo y de integridad para apoyar priorización de control.

V-B. Detección de corrupción y colusión basada en datos

La detección basada en datos parte del supuesto de que los procesos de contratación dejan huellas estructuradas. Dado que los procedimientos se repiten en el tiempo y comparten campos administrativos comparables, es posible extraer patrones de comportamiento y convertirlos en variables analíticas [18], [12]. En la literatura, estas variables operan como *red flags* y permiten estimar riesgo de manera escalable [3], [11].

Entre las señales más reportadas se encuentran: concentración de adjudicaciones en pocos proveedores, dispersión inusual de descuentos, secuencias repetitivas de participación entre los mismos oferentes y variaciones atípicas entre monto adjudicado, tiempo de ejecución y modificaciones contractuales [3], [16]. En términos teóricos, estas señales no se interpretan de forma aislada; su valor explicativo emerge cuando se analizan de manera conjunta.

Para este anteproyecto, la implicación es directa: el problema de investigación se traduce en un flujo de analítica de riesgo donde los datos administrativos se transforman en variables predictoras y, posteriormente, en un puntaje o clase de riesgo para priorizar supervisión.

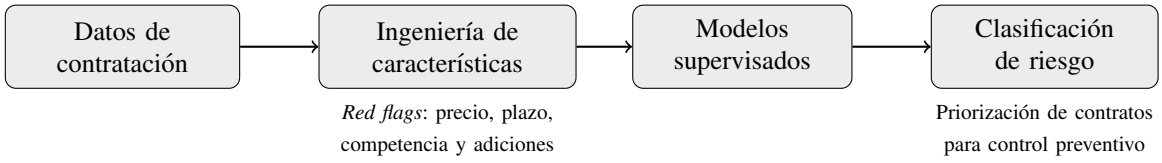

Figura 1. Esquema conceptual del enfoque de detección de riesgo en contratación pública.

Como se observa en la Figura 1, la contribución teórica del estudio consiste en conectar la literatura de *red flags* y colusión con un esquema operativo de clasificación de contratos, orientado a apoyar decisiones de vigilancia y no a sustituir el análisis jurídico posterior.

V-C. Aprendizaje automático para la predicción de riesgos

El aprendizaje automático supervisado permite estimar una función $f(\mathbf{x})$ que aproxima la relación entre un conjunto de variables contractuales $\mathbf{x}$ y una etiqueta de riesgo y derivada de evidencia histórica [12], [1]. En términos aplicados, esta formulación es pertinente para el anteproyecto porque permite pasar de descripciones agregadas a predicciones a nivel de contrato.

Los algoritmos considerados son:

1. **Regresión Logística.** Modela la probabilidad condicional de riesgo como:

$$\hat{p}(y = 1 \mid \mathbf{x}) = \sigma\left(\beta_0 + \sum_{j=1}^{p} \beta_j x_j\right), \qquad \sigma(z) = \frac{1}{1 + e^{-z}}.$$

Aquí, x_j representa la j-ésima variable del contrato (por ejemplo, modalidad, número de oferentes o historial de adiciones), y β_j cuantifica su contribución marginal sobre el logaritmo de las probabilidades. Se usa como línea base por su interpretabilidad y trazabilidad para auditoría [1].

2. **Random Forest.** Combina T árboles de decisión y obtiene la clase final por voto mayoritario:

$$\hat{y} = \operatorname{mode}\left(h_1(\mathbf{x}), h_2(\mathbf{x}), \ldots, h_T(\mathbf{x})\right).$$

Cada árbol captura interacciones no lineales; el ensamble reduce varianza y mejora estabilidad predictiva frente a ruido en los datos administrativos [3], [2].

3. **XGBoost.** Construye un ensamble aditivo de árboles, donde la predicción se expresa como:

$$\hat{y}_i = \sum_{k=1}^{K} f_k(\mathbf{x}_i), \qquad f_k \in \mathcal{F}.$$

El entrenamiento minimiza una pérdida con regularización:

$$\mathcal{L} = \sum_i l(y_i, \hat{y}_i) + \sum_k \Omega(f_k).$$

En esta formulación, $l(\cdot)$ mide el error predictivo y $\Omega(\cdot)$ penaliza complejidad del modelo para controlar sobreajuste. Esta propiedad resulta útil en datos de contratación con alta heterogeneidad [4], [12].

La selección de estos tres modelos responde a un criterio metodológico complementario: interpretabilidad (Regresión Logística), robustez no lineal (Random Forest) y capacidad predictiva de frontera (XGBoost), en línea con aplicaciones recientes en analítica de contratación [2], [1].

V-D. Evaluación de modelos y construcción de la variable objetivo

La evaluación en problemas de riesgo contractual exige métricas sensibles al desbalance de clases. Si los contratos de alto riesgo son minoría, la exactitud global puede ser alta aun con desempeño deficiente en la clase crítica. Por ello se priorizan precisión, *recall*, F1 y AUC-ROC [2], [12]. Sea TP verdaderos positivos, FP falsos positivos, TN verdaderos negativos y FN falsos negativos:

	Predicho positivo	Predicho negativo
Real positivo	TP	FN
Real negativo	FP	TN

Figura 2. Matriz de confusión para clasificación binaria de riesgo contractual.

La Figura 2 muestra que cada métrica enfatiza un tipo de error distinto. En contratación pública, perder casos riesgosos (FN) puede ser más costoso institucionalmente que revisar casos adicionales (FP), por lo que la interpretación de métricas debe alinearse con el objetivo de vigilancia preventiva.

La *precisión* mide qué proporción de contratos clasificados como riesgosos realmente lo son:

$$\text{Precisión} = \frac{TP}{TP + FP}$$

El *recall* (sensibilidad) mide cuántos contratos riesgosos reales logra detectar el modelo:

$$\text{Recall} = \frac{TP}{TP + FN}$$

El *F1-score* resume el balance entre precisión y *recall*:

$$F1 = 2 \cdot \frac{\text{Precisión} \cdot \text{Recall}}{\text{Precisión} + \text{Recall}}$$

equivalentemente,

$$F1 = \frac{2TP}{2TP + FP + FN}$$

La curva ROC compara capacidad de detección y tasa de falsas alarmas a distintos umbrales:

$$\text{TPR} = \frac{TP}{TP + FN}, \qquad \text{FPR} = \frac{FP}{FP + TN}$$

El *AUC-ROC* es el área bajo la curva ROC; valores cercanos a 1 implican mejor poder discriminativo y valores cercanos a 0.5 equivalen a un clasificador aleatorio:

$$AUC = \int_0^1 \text{TPR}(\text{FPR})\, d(\text{FPR})$$

Para robustecer la estimación se emplea validación cruzada estratificada con $k = 5$, manteniendo la proporción de clases en cada pliegue y reduciendo sesgo por particiones favorables [12], [1].

Debido a que las bases administrativas no incluyen una etiqueta jurídica explícita de "corrupción", la variable objetivo se construye con *proxies* de riesgo de incumplimiento o anomalía operacional, en línea con la literatura aplicada [6], [7], [20]. A nivel formal, para cada contrato i:

$$y_i = \begin{cases} 1, & \text{si presenta al menos una señal proxy de riesgo (adiciones reiteradas, suspensiones o} \\ & \text{desviaciones relevantes en tiempo/costo)} \\ 0, & \text{en caso contrario} \end{cases}$$

Esta definición no reemplaza el juicio legal ni la auditoría sustantiva, pero sí permite construir un sistema de alerta temprana técnicamente justificable para priorizar revisión institucional.

VI. Objetivos

VI-A. Objetivo General

Desarrollar un modelo predictivo basado en técnicas de Machine Learning que funcione como un sistema de alertas tempranas, capaz de identificar contratos públicos de infraestructura con alto riesgo de incumplimiento o asociados a procesos irregulares, en el marco del Sistema General de Regalías (SGR). Para ello, se empleará como fuente principal de información la base de datos de la plataforma SECOP II.

VI-B. Objetivos Específicos

1. Identificar y seleccionar variables relevantes de tipo contractual y financiero —como anticipos, modalidad de contratación, número de participantes y ubicación geográfica— que influyan en el riesgo de incumplimientos e irregularidades en contratos de infraestructura pública.
2. Recolectar, integrar y preprocesar los datos provenientes de la plataforma SECOP II, garantizando su calidad, consistencia y confiabilidad para el análisis predictivo.
3. Diseñar y entrenar modelos de aprendizaje supervisado, tales como Random Forest, Regresión Logística y XGBoost, con el fin de predecir de manera precisa factores de riesgo en contratos públicos.
4. Evaluar el desempeño de los modelos mediante técnicas como la validación cruzada estratificada y el uso de métricas robustas, tales como AUC, precisión, recall y F1-score, para determinar su efectividad.
5. Comparar los resultados obtenidos por los diferentes modelos con el propósito de identificar aquel que ofrezca la mayor capacidad predictiva en la detección temprana de riesgos.
6. Proponer un esquema de implementación del modelo como herramienta de alertas tempranas, orientado a fortalecer la detección de anomalías por parte de entidades de control y mecanismos de veeduría ciudadana.

VII. Alcance del Proyecto

Este proyecto se centra en construir y evaluar un modelo de aprendizaje automático capaz de estimar el nivel de riesgo de contratos públicos de infraestructura justo cuando se adjudican, antes de que comience la ejecución. La materia prima son los registros abiertos de SECOP II, particularmente los contratos que se financian con recursos del Sistema General de Regalías (SGR).

VII-A. Entregables Funcionales

Al cierre del proyecto se contará con los siguientes productos concretos:

- Un *pipeline* de extracción y preparación de datos que cubra desde la descarga de registros de SECOP II hasta la generación de un conjunto de datos listo para modelar. Esto incluye manejo de nulos, corrección de inconsistencias territoriales y la construcción indirecta de la variable de riesgo a través de indicadores *proxy*.
- Un módulo de ingeniería de características con las variables que la literatura identifica como más informativas: porcentaje de anticipo, modalidad de contratación, número de proponentes y localización del contrato.
- Un módulo de entrenamiento que compare tres clasificadores —Regresión Logística, Random Forest y XGBoost— ajustados con búsqueda aleatoria de hiperparámetros (`RandomizedSearchCV`) para mantenerse dentro de los límites computacionales del proyecto.
- Un módulo de evaluación con validación cruzada estratificada ($k = 5$) y reporte de AUC-ROC, F1-score, precisión y *recall*. Se añadirá un análisis de importancia de variables para saber qué factores pesan más en la predicción.
- El modelo seleccionado, serializado y documentado, junto con el código reproducible del experimento completo.
- Un informe técnico que compare los tres algoritmos, discuta qué variables resultaron más relevantes y proponga cómo podría escalar este trabajo hacia un Sistema de Alertas Tempranas operativo.

VII-B. Área de Estudio

El foco está puesto en contratos de infraestructura del SGR registrados en SECOP II. Se eligió ese universo por dos razones prácticas: los montos involucrados son considerables y la plataforma ofrece datos estructurados de acceso público, lo que hace viable el proyecto sin necesidad de convenios institucionales.

VII-C. Frontera del Proyecto

Para no exceder la capacidad del equipo en el tiempo disponible, quedan fuera del alcance las siguientes actividades:

- Desplegar el modelo en producción o integrarlo con los sistemas de alguna entidad de control. El trabajo termina en la validación académica del modelo.
- Desarrollar cualquier tipo de interfaz de usuario —web, móvil o de escritorio—. Los resultados se presentan en el informe y el repositorio de código.
- Ejecutar búsquedas exhaustivas de hiperparámetros (Grid Search completo), dado el costo computacional que implica sobre XGBoost con espacios de parámetros amplios.
- Detectar esquemas de corrupción que no dejen huella en los registros públicos: acuerdos verbales, testaferros no vinculados o pagos fuera del sistema. Eso requiere fuentes de inteligencia financiera que están fuera del alcance de este trabajo.

VIII. Limitaciones del Proyecto

Todo modelo predictivo tiene un techo definido por los datos y los recursos con que se construye. Reconocer esas restricciones desde el inicio no es una debilidad del proyecto: es una condición para interpretar correctamente sus resultados.

VIII-A. Limitaciones Técnicas

El entrenamiento se hará en Google Colab (GPU compartida) y equipos personales. Eso impone dos restricciones reales que vale la pena nombrar sin rodeos.

Primero, la memoria disponible por sesión puede ser insuficiente para procesar el total de registros de SECOP II de una sola vez. Según el volumen final de datos, puede ser necesario recurrir a submuestreo estratificado o dividir el procesamiento en lotes. Ninguna de las dos opciones invalida el experimento, pero sí agrega un paso de decisión metodológica que habrá que documentar.

Segundo, los espacios de búsqueda de hiperparámetros tendrán que acotarse. Una búsqueda exhaustiva sobre XGBoost con muchos parámetros puede tomar horas en los entornos disponibles, lo que hace inviable esa estrategia. La búsqueda aleatoria (`RandomizedSearchCV`) es la alternativa estándar en estos casos y produce resultados competitivos con una fracción del costo computacional, aunque sin garantía de encontrar la configuración óptima global.

Para que los experimentos sean reproducibles, se fijarán semillas aleatorias y se registrarán las versiones exactas de todas las librerías en un archivo de entorno.

VIII-B. Limitaciones de los Datos

Las restricciones de datos son más difíciles de mitigar que las técnicas, porque dependen de cómo está construida la plataforma SECOP II y de qué información el Estado colombiano publica de forma abierta.

VIII-B1. No existe una etiqueta oficial de incumplimiento: SECOP II no tiene un campo que diga si un contrato terminó mal. Para construir la variable objetivo hay que inferirla: un contrato se etiqueta como problemático si acumula varias adiciones, muestra suspensiones reiteradas o si la diferencia entre la fecha de terminación pactada y la fecha real de liquidación supera un umbral razonable. Esta aproximación introduce ruido en las etiquetas. Algunos contratos pueden quedar mal clasificados, lo que afecta la calidad del entrenamiento supervisado y hace que las métricas del modelo sean probablemente algo optimistas respecto a un escenario con etiquetas perfectas.

VIII-B2. Calidad irregular de los registros: Los datos de SECOP II no son uniformes. Hay campos vacíos, registros duplicados, municipios codificados de maneras distintas según la entidad que los ingresó y fechas con formatos inconsistentes. El pipeline de limpieza se encargará de la mayoría de estos problemas, pero es probable que un porcentaje de contratos deba descartarse por falta de información mínima. Si ese porcentaje no es aleatorio —por ejemplo, si las entidades con peor calidad de datos son también las más propensas a irregularidades— el conjunto de entrenamiento quedará sesgado.

VIII-B3. El modelo no ve lo que no está publicado: Al trabajar exclusivamente con datos abiertos, el modelo queda ciego ante irregularidades que no dejan rastro en SECOP II. Vínculos societarios entre contratistas, historial de sanciones en otras entidades o transferencias fuera del sistema no son capturables con este enfoque. Eso no hace inútil al modelo: hay suficiente evidencia internacional de que las variables contractuales públicas sí predicen riesgo. Pero sí fija un límite claro a lo que puede detectar.

IX. Plan de Trabajo

El trabajo se organiza en cuatro fases. Las dos primeras preparan los datos y las variables; las dos últimas construyen, ajustan y comparan los modelos. Algunas actividades se solapan intencionalmente: el análisis exploratorio arranca en la fase 2 porque los hallazgos descriptivos orientan qué variables conviene incluir, y la redacción del informe comienza en la fase 4 antes de que termine el análisis para no acumular toda la escritura al final.

Tabla I
Plan de trabajo por fases y actividades

Fase	Actividad	Descripción / Herramientas	Semanas
1	Recolección y limpieza	Descarga de registros SECOP II vía API o CSV. Normalización de campos, imputación de nulos, deduplicación y corrección de codificación territorial. Python, Pandas, Requests.	1 – 5
	Variable objetivo	Definición del *proxy* de incumplimiento: adiciones contractuales, suspensiones reiteradas y desfase entre fecha pactada y fecha real de liquidación. Análisis de sensibilidad del umbral elegido.	3 – 5
2	Ingeniería de características	Selección, transformación y codificación de variables predictoras (anticipos, modalidad, proponentes, ubicación). Análisis exploratorio para detectar correlaciones y desbalance de clases. Scikit-learn, Feature-engine.	5 – 8
	Pipeline de preprocesamiento	Construcción del flujo reproducible: imputación, escalado estándar y codificación *one-hot*. Serialización con `joblib` para reutilización en inferencia. Scikit-learn Pipeline.	6 – 8
3	Entrenamiento de modelos	Ajuste de Regresión Logística (línea base), Random Forest y XGBoost. Optimización con `RandomizedSearchCV` ($n_iter = 50$). Google Colab, Scikit-learn, XGBoost.	8 – 12
	Validación y métricas	Validación cruzada estratificada $k = 5$. Reporte de AUC-ROC, F1-score, precisión, *recall* y curvas PR para cada modelo.	11 – 13
4	Análisis comparativo	Comparación de modelos. Análisis de importancia con SHAP y *permutation importance*. Selección y justificación del modelo final.	13 – 15
	Informe y monografía	Redacción del informe técnico y la monografía. Organización del repositorio con código, datos de muestra y ambiente reproducible.	14 – 16

El repositorio en Git documentará cada experimento con su semilla, versión de librerías y métricas obtenidas. Eso permite retomar cualquier punto del trabajo sin tener que repetir el procesamiento completo.

X. Cronograma

X-A. Diagrama de Gantt

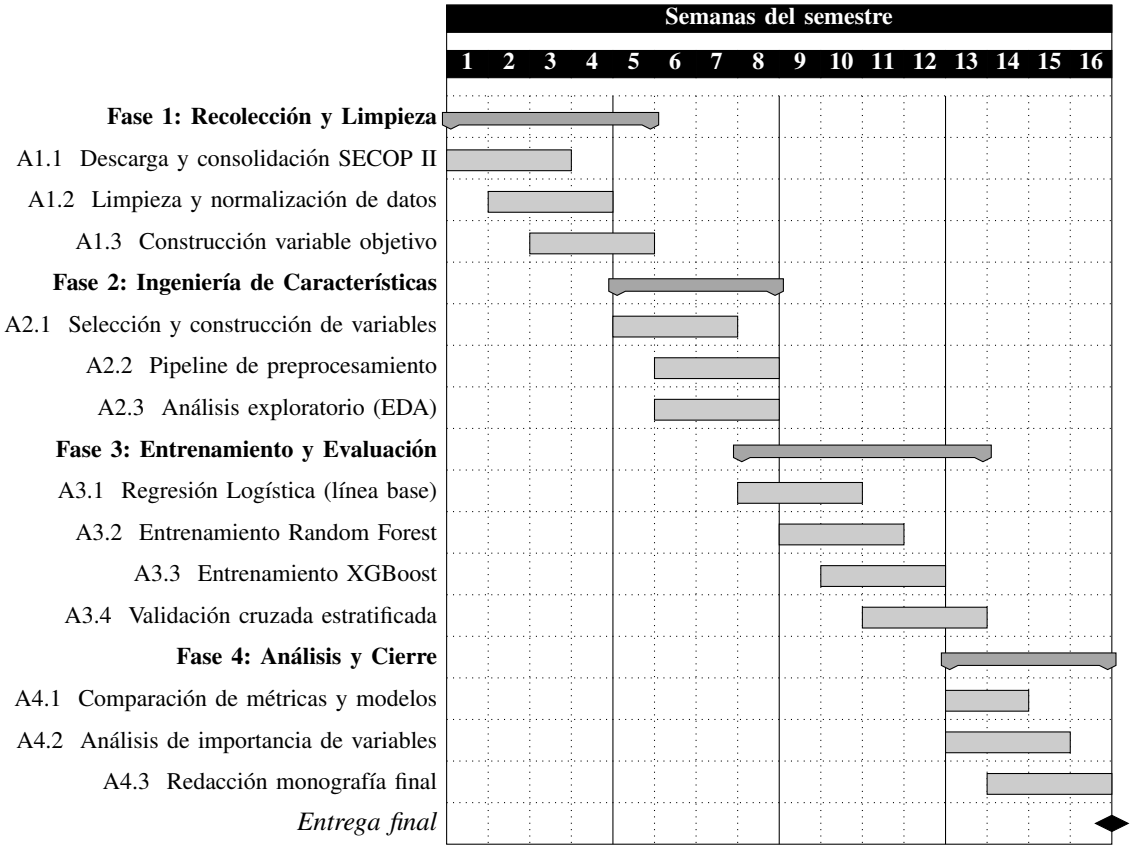

Figura 3. Diagrama de Gantt – Cronograma del proyecto (16 semanas).

X-B. Tabla de Hitos

Los hitos funcionan como puntos de control internos. Si al llegar a uno el entregable no está listo, hay margen para ajustar el ritmo antes de que el retraso se propague a la fase siguiente.

Tabla II
Hitos del proyecto

N°	Hito	Criterio de cumplimiento	Semana
H1	Datos listos	Dataset limpio, variable objetivo construida y umbral de *proxy* documentado	5
H2	Pipeline funcional	Flujo de preprocesamiento serializado, probado y versionado en el repositorio	8
H3	Modelos entrenados	Los tres clasificadores ajustados con hiperparámetros registrados en el experimento	12
H4	Evaluación cerrada	Reporte de métricas con validación cruzada completo y revisado	13
H5	Modelo seleccionado	Elección justificada del algoritmo final con análisis SHAP incluido	15
H6	Entrega final	Monografía y repositorio de código públicos y documentados	16

Referencias

[1] J. Gallego, G. Rivero, and J. Martínez, "Preventing rather than punishing: An early warning model of malfeasance in public procurement," *International Journal of Forecasting*, 2021, [Accessed: Mar. 2026]. [Online]. Available: https://doi.org/10.1016/j.ijforecast.2020.06.006

[2] A. Salazar, J. F. Pérez, and J. Gallego, "Vigia: prioritizing public procurement oversight with machine learning models and risk indices," *Data & Policy (Cambridge University Press)*, 2024, [Accessed: Mar. 2026]. [Online]. Available: https://doi.org/10.1017/dap.2024.83

[3] F. Decarolis and C. Giorgiantonio, "Corruption red flags in public procurement: new evidence from italian calls for tenders," *EPJ Data Science*, 2022, [Accessed: Mar. 2026]. [Online]. Available: https://doi.org/10.1140/epjds/s13688-022-00325-x

[4] O. Alshboul, A. Shehadeh, G. Almasabha, and A. S. Almuflih, "Extreme gradient boosting-based machine learning approach for green building cost prediction," *Sustainability*, 2022, [Accessed: Mar. 2026]. [Online]. Available: https://www.mdpi.com/1654322

[5] K. Galjanić, I. Marović, and T. Hanak, "Neural network-based approaches for predicting construction overruns with sustainability considerations," *Sustainability*, vol. 17, no. 16, 2025, [Accessed: Mar. 2026]. [Online]. Available: https://doi.org/10.3390/su17167559

[6] A. Gómez-Cabrera, S. Cortés, J. Rojas, O. Sánchez, and A. Torres, "Data-driven analysis of contracting process impact on schedule and cost performance in road infrastructure projects in colombia," *Buildings*, vol. 15, no. 2, 2025, [Accessed: Mar. 2026]. [Online]. Available: https://doi.org/10.3390/buildings15203739

[7] A. Gómez-Cabrera, L. C. León, M. L. Lopez, and A. Torres, "Analyzing time and cost deviations in educational infrastructure projects: A data-driven approach using colombia's public data platform," *Buildings*, vol. 15, no. 1, 2025, [Accessed: Mar. 2026]. [Online]. Available: https://doi.org/10.3390/buildings15193505

[8] F. C. Valencia, M.-J. P. Palacio, and T. D. López-Sanmartín, "Contratación estatal en colombia y el uso de la inteligencia artificial para la lucha contra la corrupción," *Revista de Estudos Constitucionais, Hermenêutica e Teoria do Direito*, 2025, [Accessed: Mar. 2026]. [Online]. Available: https://doi.org/10.4013/rechtd.2024.162.04

[9] J. J. S. Hernandez and O. M. Granados, "Contratación pública, corrupción y gobierno abierto en colombia," *Revista Española de la Transparencia*, 2025, [Accessed: Mar. 2026]. [Online]. Available: https://doi.org/10.51915/ret.386

[10] M. R. O. Díaz, R. M. Pabón, and A. B. M. Ceballos, "Percepción de la inteligencia artificial en la lucha contra la corrupción una exploración al caso del estado de colombia," *Revista Opera*, no. 36, pp. Enero–Junio, 2024, [Accessed: Mar. 2026]. [Online]. Available: https://dialnet.unirioja.es/servlet/articulo?codigo=9852203

[11] M. S. Lyra, B. Damásio, F. L. Pinheiro, and F. Bação, "Fraud, corruption, and collusion in public procurement activities: a systematic literature review on data-driven methods," *Applied Network Science*, 2022, [Accessed: Mar. 2026]. [Online]. Available: https://doi.org/10.1007/s41109-022-00523-6

[12] B. K. O. Tas, "A machine learning approach to detect collusion in public procurement with limited information," *Journal of Computational Social Science*, 2024, [Accessed: Mar. 2026]. [Online]. Available: https://doi.org/10.1007/s42001-024-00293-4

[13] C. R. M. Pineda, "Régimen de contratación directa en las compras públicas: límites a la facultad decisoria de contratación cuando no existe pluralidad de oferentes en el mercado," *Estudios de Derecho*, vol. 79, no. 173, 2022, [Accessed: Mar. 2026]. [Online]. Available: https://doi.org/10.17533/udea.esde.v79n173a03

[14] P. Milić, N. Veljković, and L. Stoimenov, "Using opengovb transparency indicator to evaluate national open government data," *Sustainability*, vol. 14, no. 3, 2022, [Accessed: Mar. 2026]. [Online]. Available: https://doi.org/10.3390/su14031407

[15] E. Malaret, "El nuevo reto de la contratación pública para afianzar la integridad y el control: reforzar el profesionalismo y la transparencia," *Revista Digital de Derecho Administrativo*, no. 15, 2016, [Accessed: Mar. 2026]. [Online]. Available: https://doi.org/10.18601/21452946.n15.04

[16] J. Wachs and J. Kertész, "A network approach to cartel detection in public auction markets," *Scientific Reports*, 2019, [Accessed: Mar. 2026]. [Online]. Available: https://doi.org/10.1038/s41598-019-47198-1

[17] G. Spagnolo and A. Decarolis, "Bid-rigging in public procurement: cartel strategies and bidding patterns," *Crime, Law and Social Change*, 2024, [Accessed: Mar. 2026]. [Online]. Available: https://doi.org/10.1016/j.autcon.2021.104047

[18] Y. Zhang, H. Liu, and L. Wang, "Collusion detection in public procurement auctions with machine learning algorithms," *Automation in Construction*, 2022, [Accessed: Mar. 2026]. [Online]. Available: https://doi.org/10.1016/j.autcon.2021.104047

[19] C. Morselli and P. Tremblay, "Bid-rigging networks and state-corporate crime in the construction industry," *Social Networks*, 2017, [Accessed: Mar. 2026]. [Online]. Available: https://doi.org/10.1016/j.socnet.2016.10.003

[20] M. F. D. Vanegas and A. B. Gómez, "Detección de contratistas multiobjeto mediante minería de textos para focalizar el ejercicio del control y vigilancia fiscal," *Mutis*, 2021, [Accessed: Mar. 2026]. [Online]. Available: https://doi.org/10.21789/22561498.1732